Reporte analítico CRISP-DM

SDOH Digital Twin · Motor Python/Streamlit · Emitido 19/10/2026 14:59 · Fuente: PostGIS · CDC PLACES (data.cdc.gov, cwsq-ngmh) cargado por el ETL · Tracts: 1632 · Objetivo: Salud autorreportada regular o mala (%) · Modelo seleccionado: Regresión Logística

Cada gráfico y tabla se acompaña de dos bloques: **Cómo se lee** (explicabilidad: qué método se usó y cómo interpretar la figura) e **Interpretación** (lectura de los resultados obtenidos con estos datos). Cuando se generó, se añade una **interpretación asistida por IA** (LangChain/LangFlow), que debe contrastarse con los números.

I. Comprensión del negocio

1. Mapa de la metodología CRISP-DM en la aplicación

Fase	Qué se hace	Módulo de la app
I. Negocio	Objetivos, criterios de éxito	Esta página
II. Datos	Carga del dataset real + EDA (media, mediana, moda, curtosis, atípicos, normalidad)	Carga · EDA
III. Preparación	Split estratificado, niveles por cuartiles, imputación y escalado	Preparación
IV. Modelado	Entrenamiento de 4 algoritmos + línea base, GridSearch, CV repetida, selección	Entrenamiento · Hiperparámetros · Validación · Selección
V. Evaluación	Friedman/Nemenyi, Wilcoxon-Holm, Nadeau-Bengio, McNemar, bootstrap, permutación, Spearman, Kruskal-Wallis	Pruebas inferenciales
VI. Despliegue	Predicción de escenarios, reporte PDF, asistentes LangChain y LangFlow	Despliegue · Reporte · IA

Cómo se lee. Cada fila es una de las seis fases iterativas de CRISP-DM (Chapman et al., 2000) y el módulo de esta app que la implementa. Las fases se recorren en orden; cada resultado alimenta la siguiente y todos se acumulan en el reporte PDF.

Interpretación. El flujo cubre el ciclo completo: desde datos públicos reales hasta un modelo validado estadísticamente y desplegado con explicaciones. Volver a una fase anterior (p. ej. cambiar el objetivo) invalida automáticamente los resultados de las fases posteriores para mantener la trazabilidad.

2. Criterios de éxito

Tipo	Criterio	Umbral / evidencia
Negocio	Priorizar tracts críticos de forma explicable	Cada predicción incluye su interpretación y factores
Minería de datos	F1-macro en CV claramente superior al azar (≈ 0,25)	F1 CV ≥ 0,60 y prueba de permutación $p < 0,05$
Estadístico	Selección del modelo respaldada por pruebas	Friedman + post-hoc con corrección de comparaciones múltiples
Ético	Sin datos individuales; conclusiones ecológicas	Solo agregados por census tract

Cómo se lee. Criterios definidos antes de modelar, para evaluar el resultado sin sesgo de confirmación. Los de minería de datos y estadísticos se verifican en las fases IV y V.

Interpretación. Con 4 clases equilibradas, un clasificador al azar obtiene F1 ≈ 0,25; el umbral de 0,60 exige más del doble. Además se exige significación frente a una distribución nula por permutación, de modo que el éxito no dependa de una partición afortunada.

3. Resultados de salud que se pueden modelar

Código	Resultado de salud (y)
pct_fair_poor_health	adultos que califican su salud como regular o mala
pct_diabetes	adultos con diabetes diagnosticada
pct_obesity	adultos con obesidad (IMC >= 30)
pct_high_bp	adultos con hipertensión arterial
pct_chd	adultos con enfermedad coronaria
pct_depression	adultos con depresión diagnosticada
pct_mental_distress	adultos con malestar mental frecuente (14+ días al mes)

Cómo se lee. Variables objetivo disponibles en CDC PLACES. Son prevalencias en adultos (%) por census tract; se elige una en la fase de Preparación.

Interpretación. Los determinantes sociales (entradas) nunca incluyen resultados de salud, para evitar fuga de información: el modelo aprende la relación contexto social → salud, no la fórmula de otro índice.

II. Comprensión de los datos (carga y EDA)

4. Vista previa del dataset

geoid	name	pct_no_health_insurance	pct_food_insecurity	pct_food_stamps	pct_housing_insecurity	pct_utility_shutoff	pct_no_transportation
17031010100	17031010100	10.9	24.7	23.6	20.5	13.1	12.2
17031010201	17031010201	17.1	34.6	33.9	27.2	17.6	16.3
17031010202	17031010202	11.9	21.8	19.9	17.9	11.1	10.6
17031010300	17031010300	9.9	18.2	16.1	15.3	9.3	9
17031010400	17031010400	8.4	17.7	15.3	14.7	8.9	9.6
17031010501	17031010501	7.3	14.3	12.3	13	8.1	7.9
17031010502	17031010502	7.8	14.8	12.1	12.9	7.6	8.3
17031010503	17031010503	11.1	26.6	26.5	17.1	11.7	13.7
17031010600	17031010600	8.8	15.6	13	13.7	8	8.2
17031010701	17031010701	11.3	18.4	15.3	16	9.2	9
17031010702	17031010702	16.2	28.8	26.5	23.1	14.1	13.8
17031020100	17031020100	13.6	25	21.7	20	11.7	11.5
17031020200	17031020200	8.3	12.7	9	10.6	5.5	6.2
17031020301	17031020301	6.5	11.6	9.7	8.8	5.4	6
17031020302	17031020302	10.1	17.9	15.7	13.8	8.5	8.7

geoid	pct_lack_social_support	pct_loneliness	pct_routine_checkup	pct_cholesterol_screening	pct_smoking	pct_inactivity	pct_binge_drinking
17031010100	28.6	35.8	77.5	86.5	13.7	24.2	18.2
17031010201	31.1	37.4	75.5	83.5	17.3	30.6	17.6
17031010202	26.8	33.7	77.3	87.3	12.6	23.8	18.3
17031010300	26.1	33.5	78.2	88.5	11.2	22	18.4
17031010400	25.5	36.6	73.7	83.5	10.7	18.9	21.7
17031010501	23.9	33.4	75.5	87	8.8	16.8	21.7
17031010502	24.6	35.6	73.4	84.3	8.7	16.2	22.9
17031010503	26	36.9	77.1	81.2	13.1	28	16.6
17031010600	25	34.3	74.5	86.1	9.8	17.8	22
17031010701	26.1	33.5	76.3	88	10.8	20.7	19.9
17031010702	29	36.4	73.8	83.3	14.5	26.5	19.7
17031020100	30	36.2	77.7	87.1	13	26.7	16.8
17031020200	26	33.5	77.6	89.2	8.9	18.9	18.6
17031020301	21.8	30.6	80.4	90	8.9	20.4	16.4
17031020302	24.6	32.3	78.5	88.3	11.1	23.4	17.1

geoid	pct_fair_poor_health	pct_diabetes	pct_obesity	pct_high_bp	pct_chd	pct_depression	pct_mental_distress
17031010100	21.4	12.4	35.7	32.6	5	20.3	17.3
17031010201	27.4	13.9	38.4	33.1	5.4	20.6	18.9
17031010202	20.8	12.6	33.9	32.6	5.5	19.2	15.5
17031010300	18.7	11.9	32	32.2	5.5	19.2	15
17031010400	15.5	7.6	28.9	22.5	3.3	23.5	18.4
17031010501	13.9	8.2	29.8	25.3	3.6	20.4	15.3
17031010502	13.5	6.8	27.5	21.2	2.9	21.7	16.5
17031010503	24.4	14.7	30.4	33.2	7.4	22.9	18.8
17031010600	15	8.2	29.3	24.4	3.6	20.8	15.8
17031010701	17.7	10.3	31.6	28	4.2	18.9	14.8
17031010702	23.3	11.4	35.1	28.1	4.4	20.5	17.8
17031020100	22.3	13.1	33.1	32.6	5.3	18.4	16
17031020200	14.7	9.8	25.2	27.4	4.5	17.8	13.3
17031020301	16.1	11.5	26.1	33.1	6.7	18.9	13
17031020302	19.4	12.6	30.4	32.9	6.2	19.1	14.4

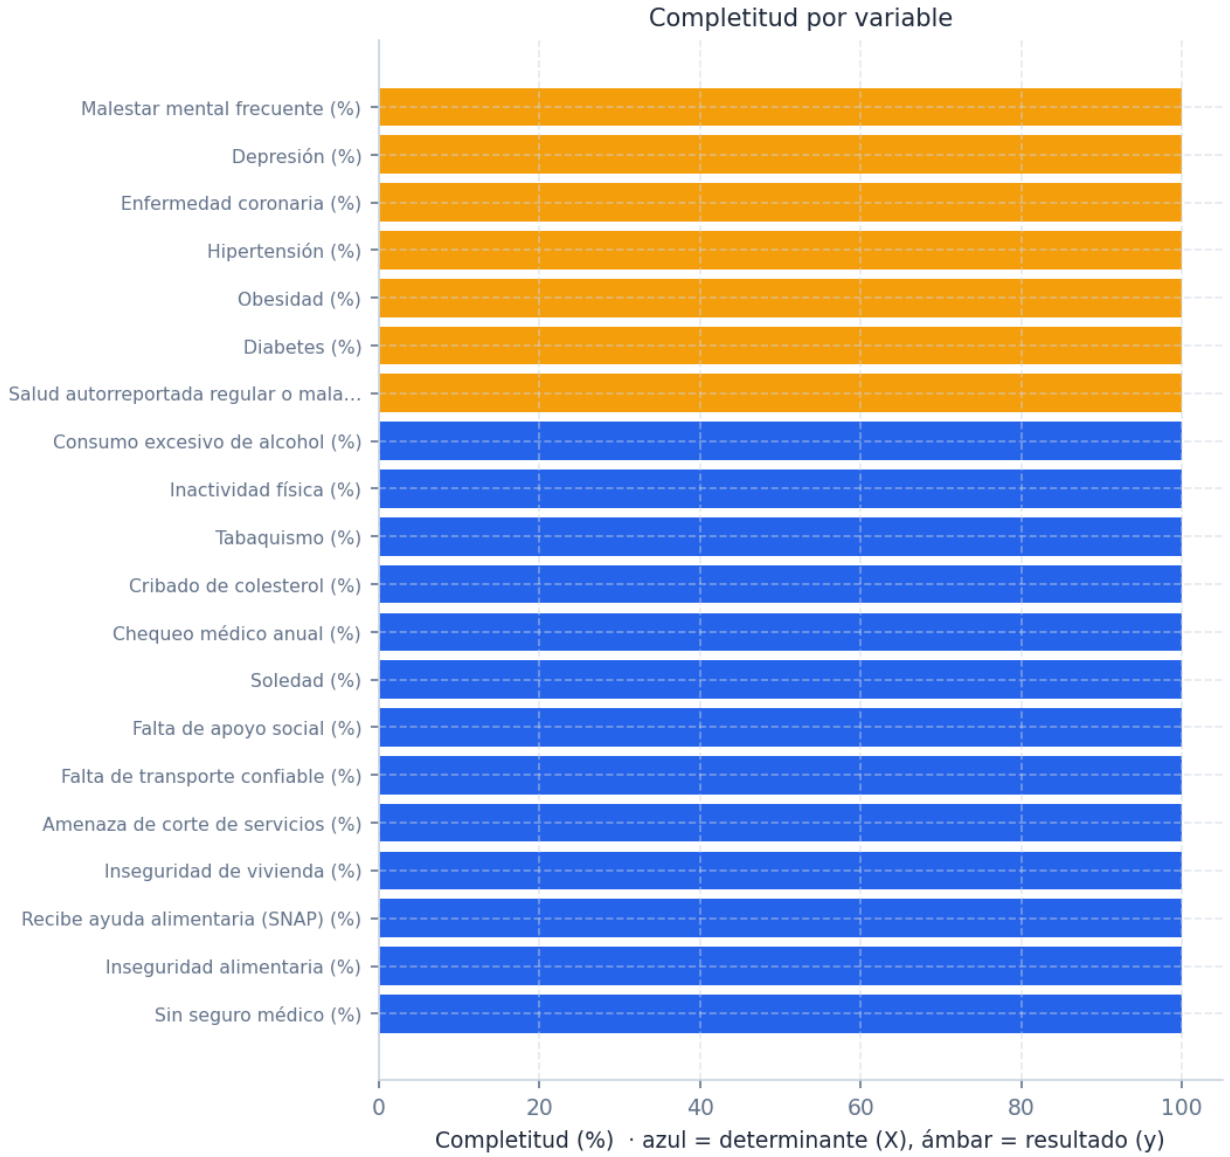
geoid	county
17031010100	Cook County
17031010201	Cook County
17031010202	Cook County
17031010300	Cook County
17031010400	Cook County
17031010501	Cook County

geoid	county
17031010502	Cook County
17031010503	Cook County
17031010600	Cook County
17031010701	Cook County
17031010702	Cook County
17031020100	Cook County
17031020200	Cook County
17031020301	Cook County
17031020302	Cook County

Cómo se lee. Cada fila es un census tract (unidad de análisis, identificado por su GEOID de 11 dígitos) y cada columna un indicador de CDC PLACES expresado como prevalencia en adultos (%). Se muestran las primeras 15 filas.

Interpretación. El dataset tiene 1632 filas y 23 columnas, con 2 condados. Los valores son estimaciones de área pequeña publicadas por el CDC (modelo con BRFSS + Census ACS), no conteos de pacientes: son datos agregados, públicos y sin información identificable.

5. Calidad de datos: completitud por variable



Código	Variable	Dominio	Rol	Observados	Faltantes	Completitud %
pct_no_health_insurance	Sin seguro médico (%)	Acceso a salud	Entrada (X)	1632	0	100
pct_food_insecurity	Inseguridad alimentaria (%)	Alimentación	Entrada (X)	1632	0	100
pct_food_stamps	Recibe ayuda alimentaria (SNAP) (%)	Ingreso	Entrada (X)	1632	0	100

Código	Variable	Dominio	Rol	Observados	Faltantes	Completitud %
pct_housing_insecurity	Inseguridad de vivienda (%)	Vivienda	Entrada (X)	1632	0	100
pct_utility_shutoff	Amenaza de corte de servicios (%)	Vivienda	Entrada (X)	1632	0	100
pct_no_transportation	Falta de transporte confiable (%)	Transporte	Entrada (X)	1632	0	100
pct_lack_social_support	Falta de apoyo social (%)	Social	Entrada (X)	1632	0	100
pct_loneliness	Soledad (%)	Social	Entrada (X)	1632	0	100
pct_routine_checkup	Chequeo médico anual (%)	Prevención	Entrada (X)	1632	0	100
pct_cholesterol_screening	Cribado de colesterol (%)	Prevención	Entrada (X)	1632	0	100
pct_smoking	Tabaquismo (%)	Comportamiento	Entrada (X)	1632	0	100
pct_inactivity	Inactividad física (%)	Comportamiento	Entrada (X)	1632	0	100
pct_binge_drinking	Consumo excesivo de alcohol (%)	Comportamiento	Entrada (X)	1632	0	100
pct_fair_poor_health	Salud autorreportada regular o mala (%)	Salud	Objetivo (y)	1632	0	100
pct_diabetes	Diabetes (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_obesity	Obesidad (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_high_bp	Hipertensión (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_chd	Enfermedad coronaria (%)	Salud crónica	Objetivo (y)	1632	0	100
pct_depression	Depresión (%)	Salud mental	Objetivo (y)	1632	0	100
pct_mental_distress	Malestar mental frecuente (%)	Salud mental	Objetivo (y)	1632	0	100

Cómo se lee. Porcentaje de tracts con valor observado en cada variable. Una completitud baja reduce la muestra útil o exige imputar; las variables sin ningún dato no pueden usarse.

Interpretación. El dataset tiene 1632 census tracts. 20 de 20 variables están completas (≥ 99,9 %).

6. Verificaciones de integridad

Verificación	Casos	Estado
Unicidad del tract (GEOID duplicados)	0	OK
Plausibilidad (valores fuera de [0, 100] %)	0	OK
Celdas faltantes en variables del modelo	0	OK

Cómo se lee. Reglas de calidad de CRISP-DM aplicadas al dataset: cada tract debe aparecer una sola vez, las prevalencias deben estar entre 0 y 100 % y se cuentan los huecos que tendrá que imputar la fase III.

Interpretación. Sin duplicados de tract y todas las prevalencias son porcentajes válidos. No hay valores faltantes.

III. Preparación de los datos

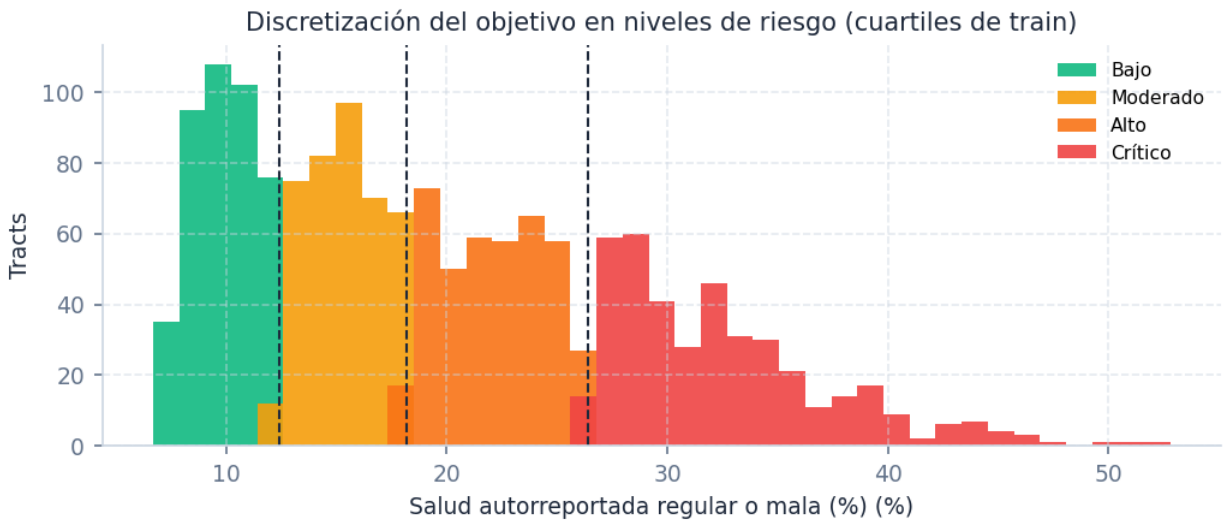
7. Pipeline de preparación

Conjunto	n	Bajo	Moderado	Alto	Crítico
Entrenamiento	1305	333	322	325	325
Prueba	327	83	80	82	82

Cómo se lee. Pipeline de preparación idéntico al de la API: (1) partición train/test estratificada por cuartiles del objetivo, (2) discretización en 4 niveles con cortes de train, (3) imputación por mediana y (4) estandarización. Imputación y escalado se ajustan dentro de cada fold de validación cruzada, evitando fuga de información.

Interpretación. El objetivo «Salud autorreportada regular o mala (%)» (%) se convierte en 4 niveles de riesgo usando los cuartiles del conjunto de entrenamiento: Bajo < 12.4 %, Moderado 12.4–18.2 %, Alto 18.2–26.4 %, Crítico ≥ 26.4 %. Los cortes se calculan solo con train para que el conjunto de prueba (20 %) no filtre información. Las clases quedan equilibradas (≈25 % cada una), de modo que F1-macro y accuracy son comparables y la línea base al azar ronda 0,25. Hay 0 celdas faltantes en train, que imputa la mediana dentro del pipeline; después se estandarizan las 13 entradas (media 0, varianza 1).

8. Definición de los niveles de riesgo



Cómo se lee. Histograma del resultado de salud coloreado por el nivel asignado. Las líneas discontinuas son los cuartiles Q1, Q2 (mediana) y Q3 calculados solo con el conjunto de entrenamiento.

Interpretación. Los cortes quedan en 12.4 %, 18.2 % y 26.4 %. El nivel Crítico agrupa el 25 % de tracts con mayor prevalencia de adultos que califican su salud como regular o mala, desde 26.4 % hasta 52.8 %: es un rango más amplio que el de los demás niveles por la asimetría positiva observada en el EDA. Los niveles son relativos al área de estudio, no umbrales clínicos.

IV. Modelado (entrenamiento, hiperparámetros, validación cruzada, selección)

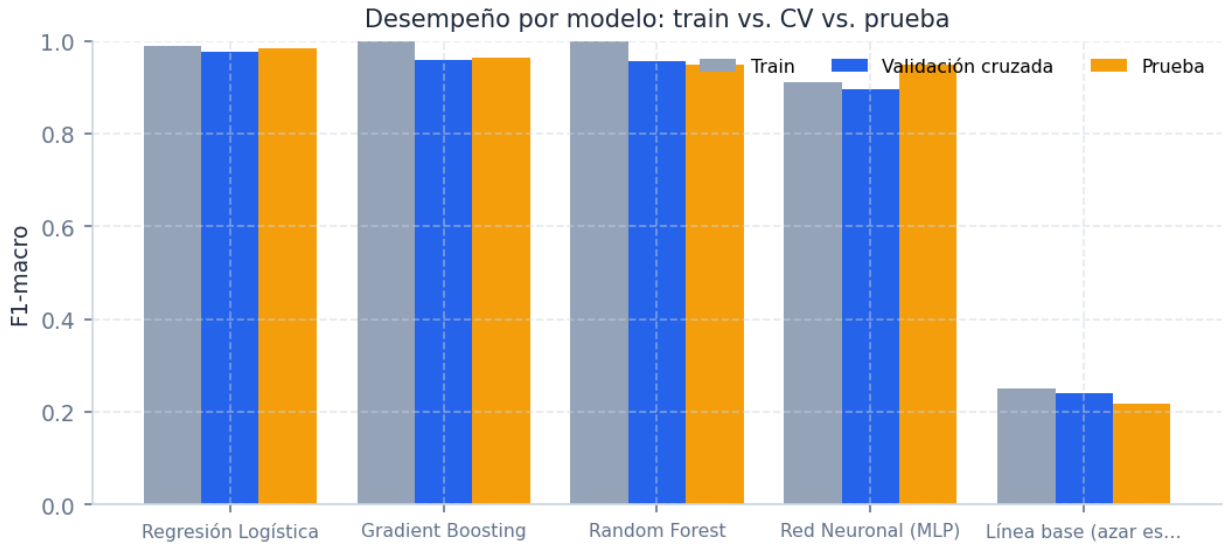
9. Algoritmos candidatos y espacio de búsqueda

Modelo	Rol	Hiperparámetros a buscar	Configuraciones
Regresión Logística	Línea base lineal e interpretable	C ∈ [0.01, 0.1, 1.0, 10.0, 100.0]	5
Random Forest	Ensamble de árboles (bagging), robusto a no linealidades	max_depth ∈ [None, 10]; min_samples_leaf ∈ [1, 4]	4
Gradient Boosting	Boosting de árboles (tipo XGBoost), fuerte en datos tabulares	learning_rate ∈ [0.05, 0.1]; max_depth ∈ [None, 6]	4
Red Neuronal (MLP)	Perceptrón multicapa, enfoque de deep learning	hidden_layer_sizes ∈ [(32,), (64, 32)]; alpha ∈ [0.0001, 0.01]	4
Línea base (azar estratificado)	Referencia: predice al azar respetando la frecuencia de clases	—	1

Cómo se lee. Cada fila es un algoritmo con su papel en la comparación y la rejilla de hiperparámetros que se explora. Todos comparten el mismo preprocesado (imputación por mediana + estandarización) dentro de un Pipeline de scikit-learn, de modo que la comparación es justa.

Interpretación. Se comparan familias complementarias: un modelo lineal interpretable, dos ensambles de árboles (bagging y boosting) y una red neuronal, más una línea base aleatoria que fija el suelo de desempeño. En total 18 configuraciones × 10 particiones.

10. Resultados del entrenamiento



Modelo	Rol	Configs. probadas	Mejores hiper parámetros	F1 train	F1 CV	F1 test	Accuracy test
Regresión Logística	Línea base lineal e interpretable	5	C=100.0	0.9879	0.9758	0.9846	0.9847
Gradient Boosting	Boosting de árboles (tipo XGBoost), fuerte en datos tabulares	4	learning_rate=0.1, max_depth=None	1	0.9585	0.963	0.9633
Random Forest	Ensamble de árboles (bagging), robusto a no linealidades	4	max_depth=10, min_samples_leaf=1	1	0.9561	0.948	0.948
Red Neuronal (MLP)	Perceptrón multicapa, enfoque de deep learning	4	alpha=0.01, hidden_layer_sizes=(64, 32)	0.9115	0.8967	0.9477	0.948
Línea base (azar estratificado)	Referencia: predice al azar respetando la frecuencia de clases	1	strategy=stratified	0.2494	0.2402	0.2187	0.2232

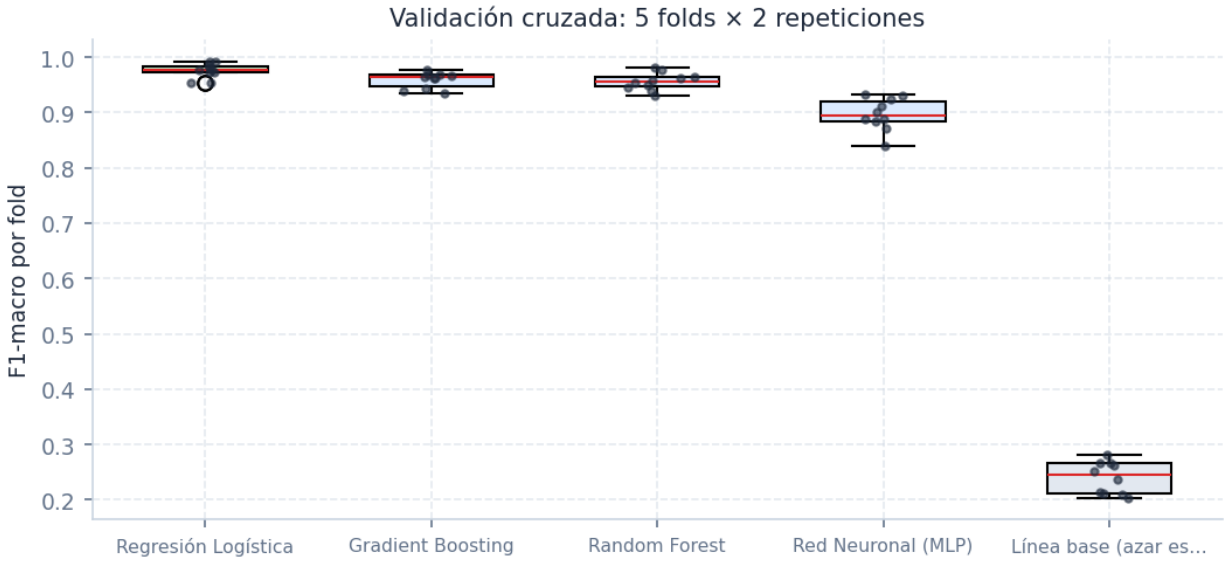
Modelo	ROC-AUC test	Tiempo (s)	Estado
Regresión Logística	0.9996	2.463	Seleccionado

Modelo	ROC-AUC test	Tiempo (s)	Estado
Gradient Boosting	0.9983	70.67	Candidato
Random Forest	0.9972	11.06	Candidato
Red Neuronal (MLP)	0.9965	2.462	Candidato
Línea base (azar estratificado)	0.4817	0.1393	Referencia

Cómo se lee. Cada algoritmo se entrena con búsqueda en rejilla (GridSearchCV) sobre el conjunto de entrenamiento. F1 train = ajuste sobre los datos vistos; F1 CV = promedio en los folds de validación (no vistos en cada ajuste); F1 test = evaluación final sobre el 20 % reservado. F1-macro promedia el F1 de las 4 clases por igual, de modo que no favorece a ninguna. ROC-AUC (uno contra el resto) mide la capacidad de ordenar tracts por riesgo (0,5 = azar, 1 = perfecto).

Interpretación. Se entrenaron 4 algoritmos más una línea base al azar, probando en total 17 configuraciones de hiperparámetros con 10 particiones de validación cruzada cada una (88 s). El mejor, Regresión Logística, alcanza F1-macro 0.976 en CV y 0.985 en prueba, frente a 0.240 del azar: el modelo aprende una señal real de los determinantes sociales (4.1× la línea base). El peor candidato es Red Neuronal (MLP) (0.897). La brecha train–CV del mejor es 0.012: sin sobreajuste apreciable.

11. Distribución del F1 por fold



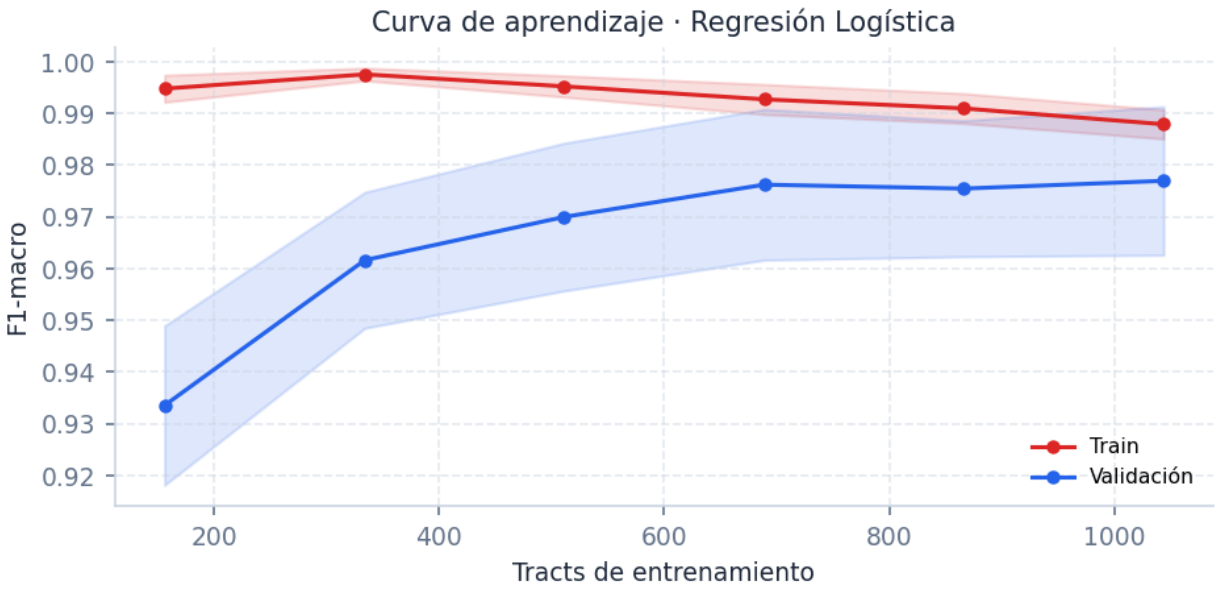
Modelo	Folds	F1 medio	Desv.	IC95% inf.	IC95% sup.	Mín	Máx
Regresión Logística	10	0.9758	0.0134	0.9662	0.9854	0.954	0.9924
Gradient Boosting	10	0.9585	0.0144	0.9482	0.9689	0.935	0.9768
Random Forest	10	0.9561	0.0157	0.9449	0.9674	0.9311	0.9807
Red Neuronal (MLP)	10	0.8967	0.0288	0.8761	0.9173	0.8403	0.9316
Línea base (azar estratificado)	10	0.2402	0.029	0.2195	0.261	0.2034	0.2804

Modelo	CV del F1 %
Regresión Logística	1.374
Gradient Boosting	1.504
Random Forest	1.64
Red Neuronal (MLP)	3.217
Línea base (azar estratificado)	12.09

Cómo se lee. Validación cruzada estratificada repetida: el conjunto de entrenamiento se divide en k partes con la misma proporción de niveles; se entrena en k–1 y se valida en la restante, rotando, y todo se repite con otra semilla. Todos los modelos usan exactamente las mismas particiones, lo que permite compararlos por pares. Cada punto es el F1 de un fold; el IC 95 % usa la distribución t de Student.

Interpretación. El mejor modelo (Regresión Logística) obtiene F1 = 0.9758 con IC 95 % [0.9662, 0.9854] sobre 10 folds; su F1 oscila entre 0.954 y 0.992. Su intervalo se solapa con el del segundo (Gradient Boosting), por lo que la diferencia puede no ser real: se contrasta formalmente en «Pruebas inferenciales». El modelo más estable entre particiones es Regresión Logística (desv. 0.0134). Una desviación baja indica que el desempeño no depende de qué tracts caen en cada fold.

12. Curva de aprendizaje del modelo seleccionado



Cómo se lee. Se reentrena el modelo seleccionado con fracciones crecientes del entrenamiento (15 %–100 %) y se mide el F1 en train y en validación (5 folds). Bandas = ± 1 desviación. Si ambas curvas convergen en un valor bajo hay sesgo (modelo demasiado simple); si quedan separadas hay varianza (sobreajuste) y más datos ayudarían.

Interpretación. Con 156 tracts el F1 de validación es 0.934 y con 1044 llega a 0.977; el último incremento de datos aporta +0.002. La curva se ha estabilizado: más datos del mismo tipo aportarían poco. La distancia final train–validación es 0.011 (varianza contenida).

13. Ranking de candidatos y criterio de selección

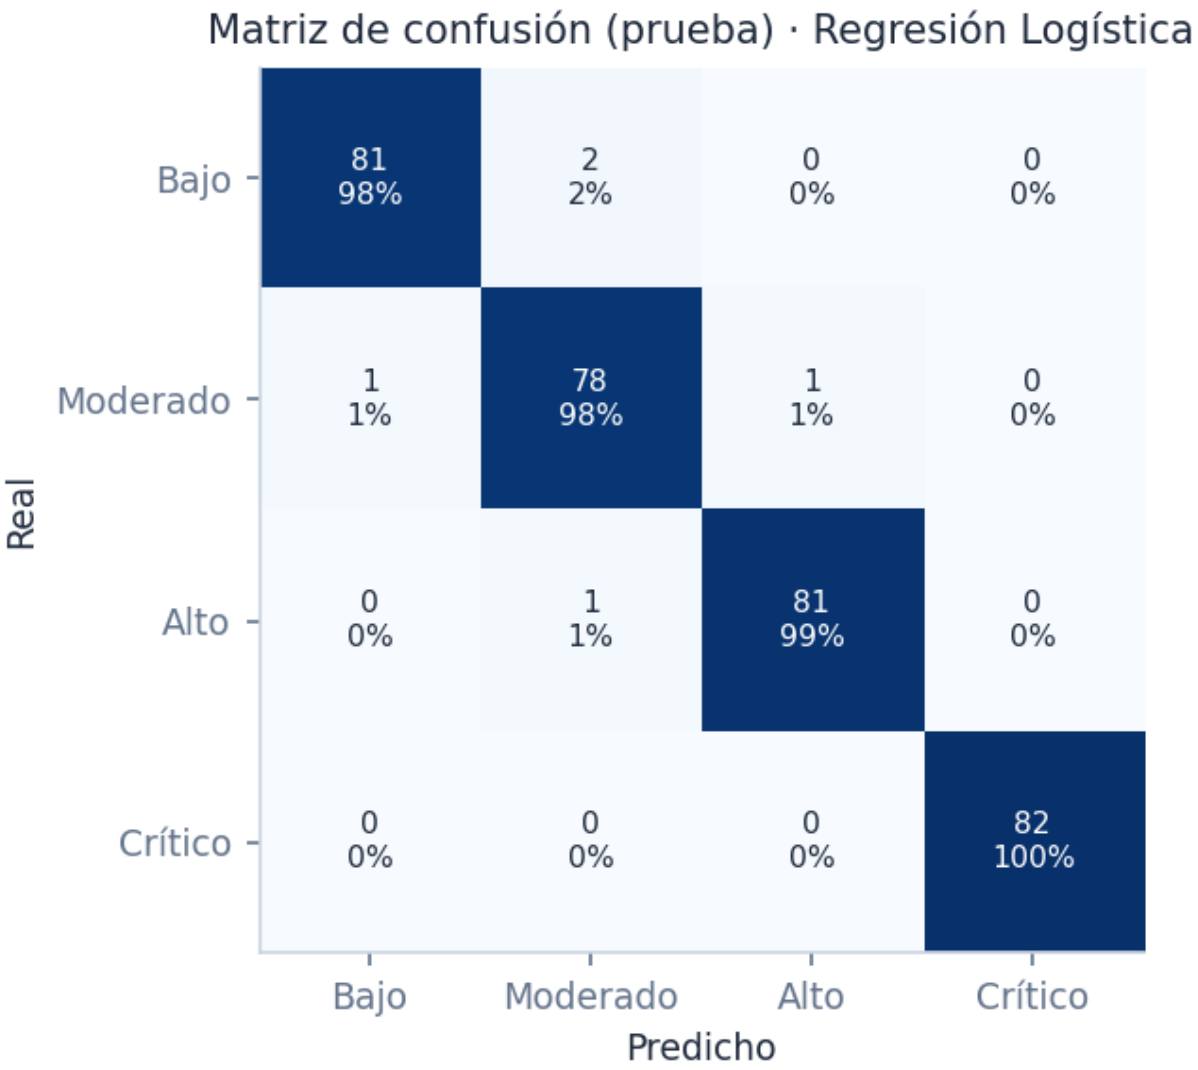
Puesto	Modelo	F1 CV	± desv.	F1 test	Accuracy balanceada	Kappa de Cohen	ROC-AUC
1	Regresión Logística	0.9758	0.0134	0.9846	0.9847	0.9796	0.9996
2	Gradient Boosting	0.9585	0.0144	0.963	0.963	0.9511	0.9983
3	Random Forest	0.9561	0.0157	0.948	0.9479	0.9307	0.9972
4	Red Neuronal (MLP)	0.8967	0.0288	0.9477	0.9476	0.9307	0.9965

Puesto	Sobreajuste (train–CV)	Tiempo (s)
1	0.0121	2.463
2	0.0415	70.67
3	0.0439	11.06
4	0.0148	2.462

Cómo se lee. Ranking de candidatos por F1-macro en validación cruzada. Se añaden métricas de prueba complementarias: accuracy balanceada (media de sensibilidades), kappa de Cohen (acuerdo corregido por azar: 0 = azar, 1 = perfecto), ROC-AUC y la brecha train–CV como indicador de sobreajuste.

Interpretación. Criterio declarado: mayor F1-macro medio en validación cruzada (el test no se usa para elegir, solo para confirmar). Gana Regresión Logística con 0.9758, +0.0173 sobre Gradient Boosting. En prueba confirma F1 = 0.9846, ROC-AUC = 0.9996 y kappa = 0.980 (acuerdo casi perfecto más allá del azar). El más rápido es Red Neuronal (MLP) (2.5 s). Si la ventaja del ganador no resulta estadísticamente significativa en la fase inferencial, un modelo más simple o rápido sería una alternativa igualmente defendible.

14. Matriz de confusión del modelo seleccionado



Cómo se lee. Filas = nivel real del tract, columnas = nivel predicho por el modelo, sobre el 20 % de prueba que nunca participó en el entrenamiento. Cada celda muestra el número de tracts y el porcentaje de su fila (sensibilidad por clase en la diagonal). Un modelo perfecto concentra todo en la diagonal.

Interpretación. De 327 tracts de prueba, 322 (98%) se clasifican en su nivel exacto y 5 (2%) en un nivel vecino; solo 0 (0%) fallan por dos o más niveles. Los errores se concentran junto a la diagonal porque los niveles son cuartiles de una variable continua: confundir Alto con Crítico es un error de frontera, no de concepto. La clase mejor reconocida es Crítico (sensibilidad 100%) y la peor Moderado (98%); las clases intermedias suelen ser las más difíciles al tener vecinos por ambos lados. Para priorizar intervenciones importa el nivel Crítico: sensibilidad 100% y precisión 100%.

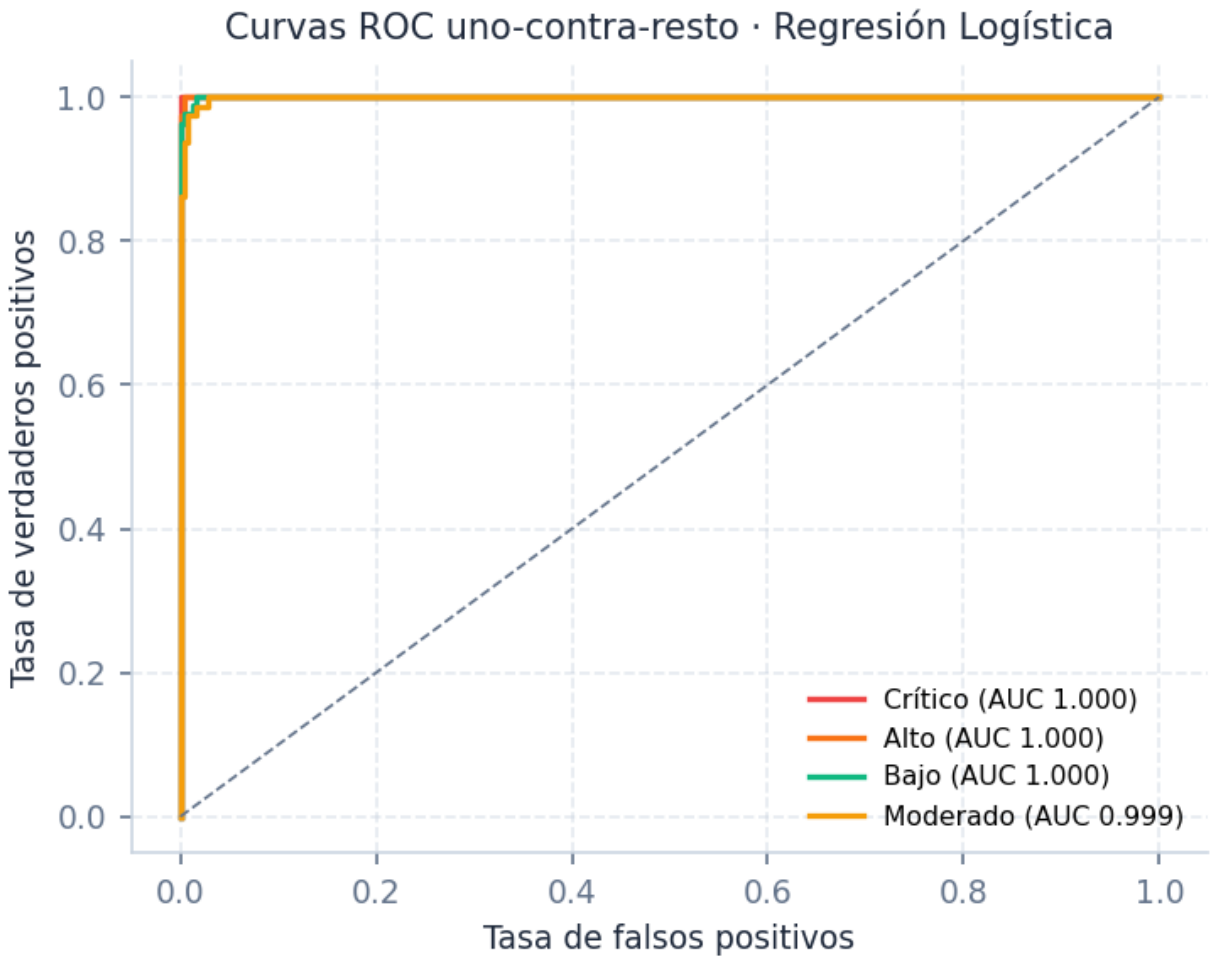
15. Métricas por nivel de riesgo

Nivel	Precisión	Sensibilidad (recall)	F1	Soporte
Bajo	0.9878	0.9759	0.9818	83
Moderado	0.963	0.975	0.9689	80
Alto	0.9878	0.9878	0.9878	82
Crítico	1	1	1	82
Promedio macro	0.9846	0.9847	0.9846	327

Cómo se lee. Precisión: de los tracts que el modelo etiqueta con ese nivel, qué fracción lo es realmente (pocas falsas alarmas). Sensibilidad: de los tracts que realmente son de ese nivel, qué fracción detecta (pocos casos perdidos). F1: media armónica de ambas. Soporte: tracts reales de cada nivel en prueba.

Interpretación. El nivel mejor predicho es Crítico (F1 = 1.000) y el más difícil Moderado (F1 = 0.969). Los niveles extremos (Bajo y Crítico) suelen separarse mejor porque sus determinantes sociales son más distintivos; los intermedios comparten perfil con dos vecinos. Si la precisión de Crítico supera a su sensibilidad, el modelo es conservador (marca pocos críticos pero acierta); si es al revés, detecta más casos a costa de falsas alarmas.

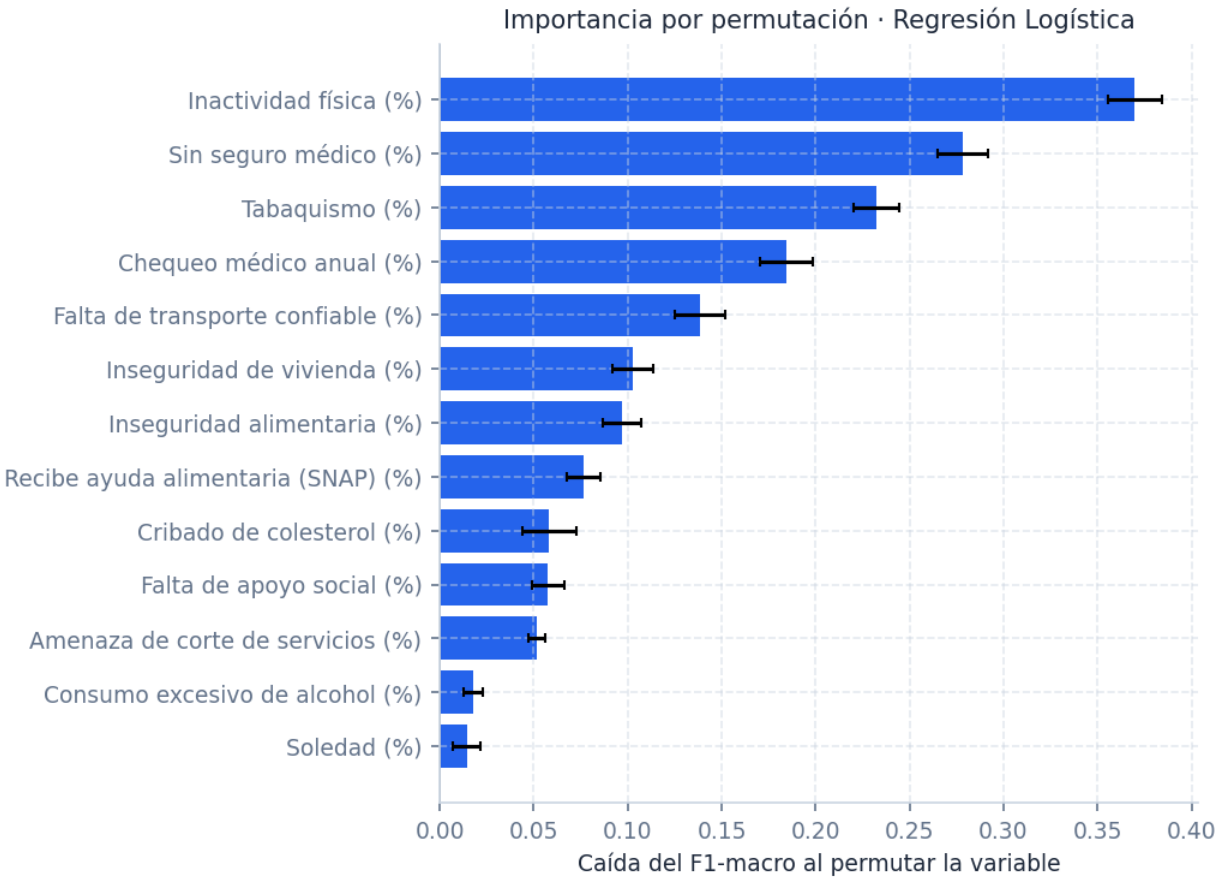
16. Curvas ROC por nivel



Cómo se lee. Para cada nivel se trata el problema como binario (ese nivel contra los demás) y se barre el umbral de probabilidad. La curva muestra cuántos verdaderos positivos se ganan a cambio de falsos positivos; la diagonal gris es el azar (AUC = 0,5). Cuanto más pegada a la esquina superior izquierda, mejor.

Interpretación. AUC macro = 1.000. Por nivel: Crítico 1.000, Alto 1.000, Bajo 1.000, Moderado 0.999. Un AUC de 0,9 significa que, tomando al azar un tract de ese nivel y otro que no lo es, el modelo asigna mayor probabilidad al correcto el 90 % de las veces. El nivel Moderado es el más difícil de separar del resto.

17. Explicabilidad global: importancia por permutación



Variable	Importancia	Desv.
Inactividad física (%)	0.3697	0.0144
Sin seguro médico (%)	0.2785	0.0134
Tabaquismo (%)	0.2325	0.0122
Chequeo médico anual (%)	0.1843	0.0141
Falta de transporte confiable (%)	0.1384	0.0135
Inseguridad de vivienda (%)	0.1028	0.0107
Inseguridad alimentaria (%)	0.0969	0.0102
Recibe ayuda alimentaria (SNAP) (%)	0.0766	0.0091
Cribado de colesterol (%)	0.0584	0.0146
Falta de apoyo social (%)	0.0576	0.0087
Amenaza de corte de servicios (%)	0.0516	0.0046
Consumo excesivo de alcohol (%)	0.0177	0.0049
Soledad (%)	0.0144	0.0073

Cómo se lee. Importancia por permutación (explicabilidad agnóstica al modelo): se desordenan al azar los valores de una variable en el conjunto de prueba, 10 veces, y se mide cuánto cae el F1-macro. Si el modelo depende de esa variable, desordenarla lo empeora mucho. Barra de error = ± 1 desv.

Interpretación. Las variables que más sostienen las predicciones son: «Inactividad física (%)» (–0.370 de F1 si se desordena), «Sin seguro médico (%)» (–0.279 de F1 si se desordena), «Tabaquismo (%)» (–0.233 de F1 si se desordena). 0 variables tienen una importancia indistinguible de cero (su efecto no supera su propia variabilidad). Al estar los determinantes correlacionados, una variable puede parecer poco importante porque otra correlacionada aporta la misma información; la importancia es predictiva, no causal.

V. Evaluación (pruebas inferenciales robustas)

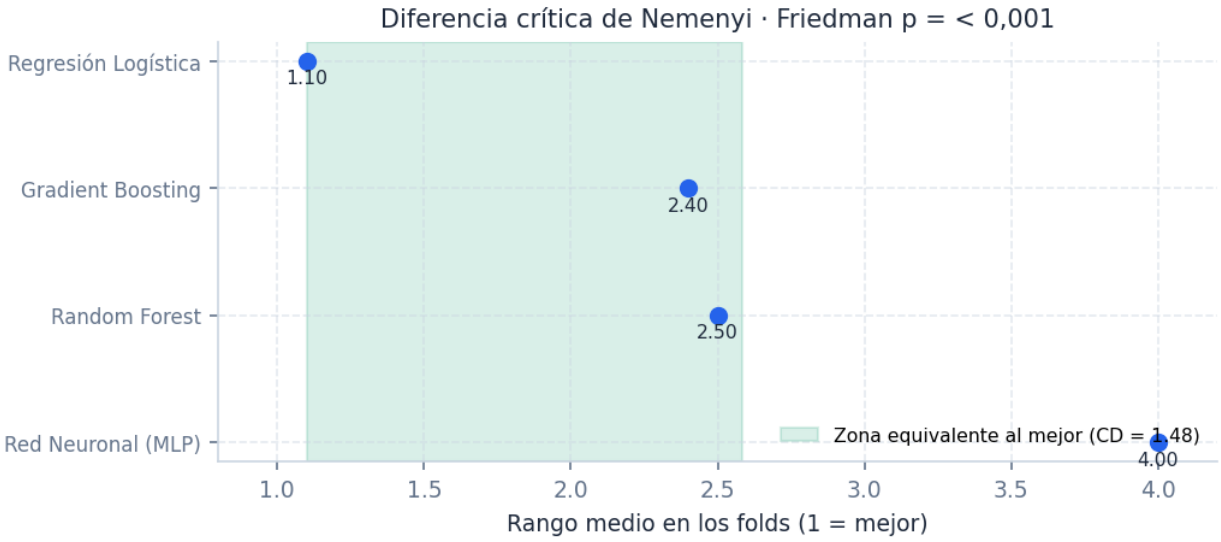
18. Prueba de Friedman y post-hoc de Nemenyi

Modelo	Rango medio (1 = mejor)	Distancia al mejor	¿Distinguible del mejor? (Nemenyi)
Regresión Logística	1.1	0	—
Gradient Boosting	2.4	1.3	No
Random Forest	2.5	1.4	No
Red Neuronal (MLP)	4	2.9	Sí

Cómo se lee. Prueba de Friedman: alternativa no paramétrica al ANOVA de medidas repetidas. En cada fold se ordenan los modelos (1 = mejor F1) y se contrasta H0 «todos los modelos tienen el mismo rango medio». W de Kendall (0–1) es el tamaño del efecto. Post-hoc de Nemenyi: dos modelos difieren si sus rangos medios se separan más que la diferencia crítica CD (Demšar, 2006).

Interpretación. Friedman χ^2 = 25.32 con 3 g.l., p = < 0,001 sobre 10 folds. Se rechaza H0: al menos un modelo rinde distinto. El tamaño del efecto (W de Kendall = 0.844) es grande, es decir, la ordenación de modelos es muy consistente entre folds. Con la diferencia crítica de Nemenyi (CD = 1.483 rangos) no se distinguen del mejor: Gradient Boosting, Random Forest; ese grupo es estadísticamente equivalente.

19. Diagrama de diferencia crítica



Cómo se lee. Cada punto es el rango medio de un modelo en los folds de validación cruzada. La banda verde se extiende desde el mejor modelo una distancia igual a la diferencia crítica de Nemenyi: los modelos dentro de la banda no son estadísticamente distinguibles del ganador.

Interpretación. Regresión Logística ocupa el mejor rango medio (1.10). Dentro de la banda (equivalentes al mejor): Gradient Boosting, Random Forest. Fuera de la banda (significativamente peores): Red Neuronal (MLP). Si varios modelos comparten banda, la elección entre ellos puede basarse en criterios secundarios como interpretabilidad o coste computacional.

20. Comparaciones por pares: Wilcoxon y t corregida de Nadeau-Bengio (Holm)

Modelo A	Modelo B	Δ F1 medio (A–B)	Wilcoxon p	t Nadeau-Bengio	p corregida N-B	r rango-biserial	Wilcoxon p (Holm)
Regresión Logística	Gradient Boosting	0.0173	0.002	3.877	0.0037	1	0.0137
Regresión Logística	Random Forest	0.0197	0.0039	3.029	0.0143	0.9636	0.0137
Regresión Logística	Red Neuronal (MLP)	0.0791	0.002	4.165	0.0024	1	0.0137
Gradient Boosting	Random Forest	0.0024	0.4922	0.5283	0.6101	0.2727	0.4922
Gradient Boosting	Red Neuronal (MLP)	0.0618	0.002	3.035	0.0141	1	0.0137
Random Forest	Red Neuronal (MLP)	0.0594	0.002	2.657	0.0262	1	0.0137
Regresión Logística	Línea base (azar estratificado)	0.7356	0.002	34.55	0	1	0.0137

Modelo A	N-B p (Holm)	¿Diferencia significativa?
Regresión Logística	0.0187	Sí (ambas)
Regresión Logística	0.0566	Solo una prueba

Modelo A	N-B p (Holm)	¿Diferencia significativa?
Regresión Logística	0.0146	Sí (ambas)
Gradient Boosting	0.6101	No
Gradient Boosting	0.0566	Solo una prueba
Random Forest	0.0566	Solo una prueba
Regresión Logística	0	Sí (ambas)

Cómo se lee. Wilcoxon de rangos con signo: compara los F1 de dos modelos fold a fold (pareado, sin suponer normalidad). t corregida de Nadeau-Bengio (2003): corrige la varianza por el solapamiento entre conjuntos de entrenamiento de la CV, que hace que la t clásica tenga demasiados falsos positivos. Holm ajusta los p-valores por hacer muchas comparaciones. Se declara diferencia robusta solo si ambas pruebas la respaldan.

Interpretación. Se contrastan 7 pares con dos pruebas y corrección de Holm por comparaciones múltiples. Regresión Logística supera de forma robusta (ambas pruebas) a: Gradient Boosting, Red Neuronal (MLP), Línea base (azar estratificado). Frente a Random Forest la diferencia no es concluyente: la t corregida de Nadeau-Bengio es más conservadora que Wilcoxon porque tiene en cuenta que los folds comparten datos de entrenamiento. El r rango-biserial (–1 a 1) indica en qué proporción de folds gana A: |r| > 0,5 es un efecto grande.

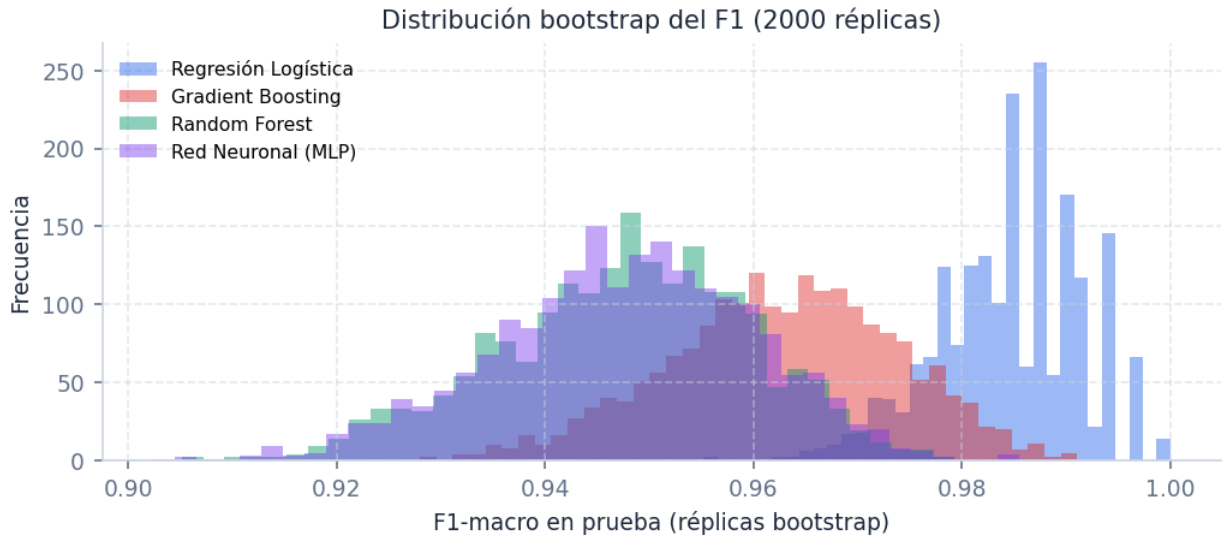
21. Prueba de McNemar: Regresión Logística vs. Gradient Boosting

	Gradient Boosting acierta	Gradient Boosting falla
Regresión Logística acierta	312	10
Regresión Logística falla	3	2

Cómo se lee. Tabla de contingencia 2×2 de aciertos/errores de los dos mejores modelos sobre el mismo conjunto de prueba. La prueba de McNemar (versión exacta binomial) contrasta si los desacuerdos se reparten 50/50; es la prueba recomendada por Dietterich (1998) para comparar dos clasificadores con un único conjunto de prueba.

Interpretación. Sobre los mismos tracts de prueba, Regresión Logística acierta donde Gradient Boosting falla en 10 casos y al revés en 3. Solo esas celdas discordantes informan de la diferencia. McNemar exacto: p = 0.0923 (χ^2 con corrección de continuidad = 2.77, p = 0.0961). No es significativa: ambos modelos cometen una cantidad de errores compatible con el azar sobre este conjunto de prueba.

22. Intervalos de confianza bootstrap del F1 de prueba



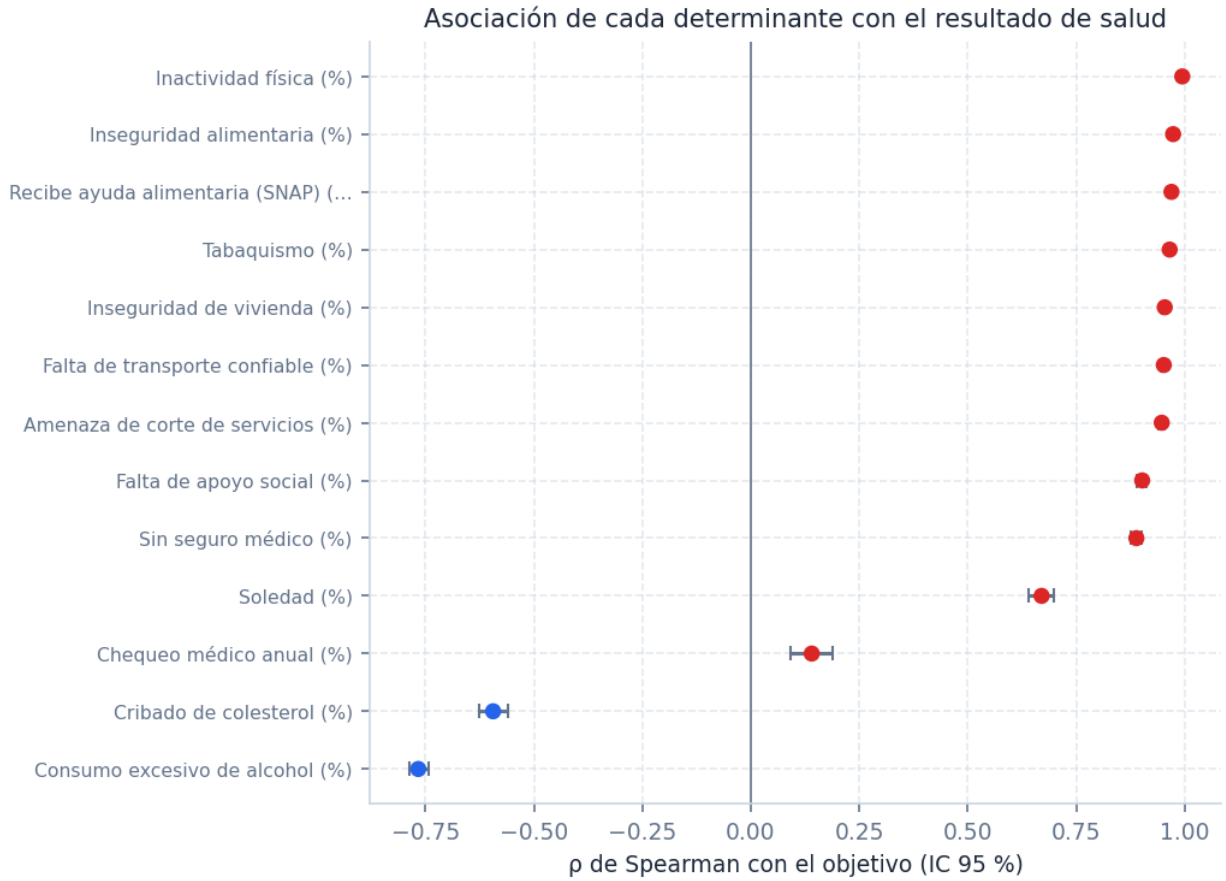
Modelo	F1 test	IC95% inf.	IC95% sup.	Amplitud IC
Regresión Logística	0.9846	0.9698	0.9968	0.0271
Gradient Boosting	0.963	0.9404	0.9824	0.0421
Random Forest	0.948	0.9225	0.9692	0.0467
Red Neuronal (MLP)	0.9477	0.9221	0.9699	0.0478
Línea base (azar estratificado)	0.2187	0.1742	0.2608	0.0867

Cómo se lee. Bootstrap percentil: se remuestrean con reemplazo los tracts de prueba 2.000 veces y se recalcula el F1 en cada réplica. El 2,5 % y 97,5 % de esas réplicas forman el IC 95 %. La diferencia entre modelos se calcula en las MISMAS réplicas (bootstrap pareado). No asume ninguna distribución.

Interpretación. El F1 de prueba del mejor modelo (Regresión Logística) es 0.9846 con IC 95 % bootstrap [0.9698, 0.9968]: esa es la incertidumbre por haber evaluado sobre una muestra finita de tracts. La diferencia pareada Regresión Logística – Gradient Boosting vale +0.0217 con IC 95 % [-0.0000, +0.0447]; el intervalo incluye el 0 (en el 3% de las réplicas el segundo

iguala o supera al primero), así que la ventaja no está garantizada.

23. Correlación de Spearman con «Salud autorreportada regular o mala (%)» (IC 95 %, Holm)



Variable	n	ρ Spearman	IC95% inf.	IC95% sup.	p	p (Holm)	Fuerza
Inactividad física (%)	1632	0.9945	0.9938	0.9951	0	0	Fuerte
Inseguridad alimentaria (%)	1632	0.9734	0.9701	0.9763	0	0	Fuerte
Recibe ayuda alimentaria (SNAP) (%)	1632	0.9696	0.9659	0.9729	0	0	Fuerte
Tabaquismo (%)	1632	0.9655	0.9613	0.9693	0	0	Fuerte
Inseguridad de vivienda (%)	1632	0.9541	0.9486	0.9591	0	0	Fuerte
Falta de transporte confiable (%)	1632	0.9519	0.9461	0.9571	0	0	Fuerte
Amenaza de corte de servicios (%)	1632	0.9472	0.9408	0.9529	0	0	Fuerte
Falta de apoyo social (%)	1632	0.9021	0.8908	0.9123	0	0	Fuerte
Sin seguro médico (%)	1632	0.8888	0.8762	0.9003	0	0	Fuerte
Consumo excesivo de alcohol (%)	1632	-0.7664	-0.7882	-0.7426	0	0	Fuerte
Soledad (%)	1632	0.6703	0.6397	0.6989	0	0	Fuerte
Cribado de colesterol (%)	1632	-0.5939	-0.627	-0.5588	0	0	Fuerte
Chequeo médico anual (%)	1632	0.1405	0.0924	0.188	0	0	Débil

Cómo se lee. Correlación de rangos de Spearman entre cada determinante y el % del resultado de salud (no requiere normalidad ni linealidad). IC 95 % por transformación de Fisher con el error estándar de Bonett-Wright para Spearman. Holm controla los falsos positivos al contrastar todas las variables a la vez. Fuerza: < 0,1 despreciable, 0,1–0,3 débil, 0,3–0,5 moderada, ≥ 0,5 fuerte.

Interpretación. 13 de 13 determinantes se asocian significativamente con «Salud autorreportada regular o mala (%)» tras Holm. Asociados a MAYOR prevalencia: «Inactividad física (%)» (ρ = +0.99), «Inseguridad alimentaria (%)» (ρ = +0.97), «Recibe ayuda alimentaria (SNAP) (%)» (ρ = +0.97). Asociados a MENOR prevalencia (factores protectores): «Consumo excesivo de alcohol (%)» (ρ = -0.77), «Cribado de colesterol (%)» (ρ = -0.59). Los intervalos estrechos reflejan el tamaño muestral; con n grande incluso ρ pequeñas son significativas, por eso se interpreta la fuerza (|ρ|) y no solo el p-valor. Son asociaciones ecológicas entre tracts, no efectos causales individuales.

24. Kruskal-Wallis: determinantes por nivel de riesgo (ε²)

Variable	H	p	ε²	Mediana Bajo	Mediana Moderado	Mediana Alto	Mediana Crítico
Inactividad física (%)	1515	0	0.929	13.2	19.3	26.6	35.5
Inseguridad alimentaria (%)	1458	0	0.8936	7.4	13.1	24.7	41

Variable	H	p	ε^2	Mediana Bajo	Mediana Moderado	Mediana Alto	Mediana Crítico
Recibe ayuda alimentaria (SNAP) (%)	1442	0	0.8841	5.2	10.05	20.1	41
Tabaquismo (%)	1432	0	0.8776	5.9	9.3	12.1	17.2
Inseguridad de vivienda (%)	1408	0	0.8631	7.2	11.2	20.1	31.7
Falta de transporte confiable (%)	1400	0	0.8584	4.5	6.6	11.2	18.8
Amenaza de corte de servicios (%)	1381	0	0.8465	4	6.1	10.8	20.4
Falta de apoyo social (%)	1267	0	0.7766	21.2	24.6	29.4	34.9
Sin seguro médico (%)	1248	0	0.7647	4.6	7.7	13	17.7
Consumo excesivo de alcohol (%)	885.3	0	0.542	23.5	19.4	18.7	14.4
Soledad (%)	803.7	0	0.4918	32.8	32.7	36.2	40
Cribado de colesterol (%)	594.8	0	0.3635	89.7	89.45	86.9	84.3
Chequeo médico anual (%)	36.09	0	0.0203	77.3	77.95	76.8	79.6

Variable	p (Holm)	Efecto
Inactividad física (%)	0	Grande
Inseguridad alimentaria (%)	0	Grande
Recibe ayuda alimentaria (SNAP) (%)	0	Grande
Tabaquismo (%)	0	Grande
Inseguridad de vivienda (%)	0	Grande
Falta de transporte confiable (%)	0	Grande
Amenaza de corte de servicios (%)	0	Grande
Falta de apoyo social (%)	0	Grande
Sin seguro médico (%)	0	Grande
Consumo excesivo de alcohol (%)	0	Grande
Soledad (%)	0	Grande
Cribado de colesterol (%)	0	Grande
Chequeo médico anual (%)	0	Pequeño

Cómo se lee. Kruskal-Wallis: alternativa no paramétrica al ANOVA de un factor. Contrasta si la distribución de un determinante es la misma en los 4 niveles de riesgo (H0). $\varepsilon^2 = (H - k + 1)/(n - k)$ es el tamaño del efecto: proporción de la variabilidad en rangos explicada por el nivel (0,01 pequeño, 0,08 mediano, 0,26 grande). Se muestran las medianas por nivel para leer la dirección.

Interpretación. 13 de 13 determinantes difieren significativamente entre los cuatro niveles de riesgo. 12 con efecto grande ($\varepsilon^2 \geq 0{,}26$). El más discriminante es «Inactividad física (%)» ($\varepsilon^2 = 0.929$): su mediana pasa de 13.2 % en tracts de riesgo Bajo a 35.5 % en los Críticos. Estas variables son las que permiten al modelo separar los niveles, y coinciden en buena medida con la importancia por permutación.

25. Kruskal-Wallis: «Salud autorreportada regular o mala (%)» entre condados

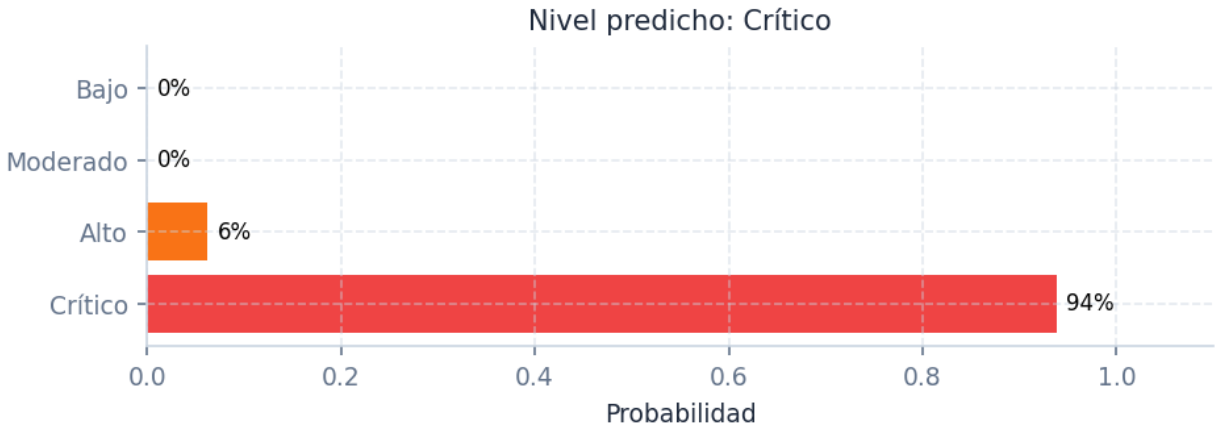
Condado	Tracts	Mediana	RIC
Cook County	1328	19.35	13.2
New York County	304	11.6	11.15

Cómo se lee. Kruskal-Wallis del objetivo entre condados del área de estudio. Detecta heterogeneidad geográfica que afecta a la transferibilidad del modelo. Se muestran mediana y RIC por condado.

Interpretación. Kruskal-Wallis H = 108.49, p = < 0,001, $\varepsilon^2 = 0.066$ con 2 condados. La prevalencia de «Salud autorreportada regular o mala (%)» difiere entre condados: la mediana más alta es la de Cook County (19.4 %) y la más baja la de New York County (11.6 %). Por eso los niveles de riesgo son relativos al área de estudio completa y un modelo entrenado aquí debe recalibrarse antes de aplicarse a otro territorio.

VI. Despliegue (predicción e IA)

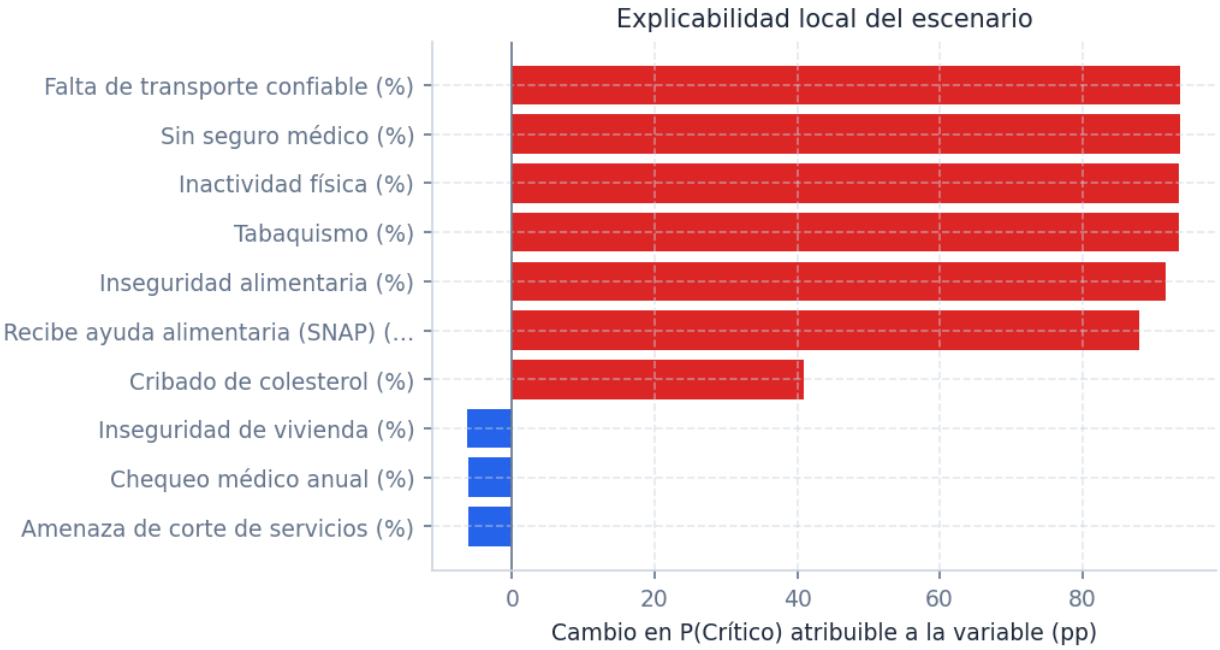
26. Predicción del escenario simulado



Cómo se lee. Probabilidad que el modelo seleccionado asigna a cada nivel de riesgo para el tract simulado. El nivel predicho es el de mayor probabilidad; la diferencia con el segundo indica la seguridad de la predicción.

Interpretación. El escenario se clasifica como CRÍTICO (≥ 26.4 % de Salud autorreportada regular o mala (%)) con probabilidad 94%; la segunda opción es Alto (6%). La decisión es clara. Lo que más empuja hacia este nivel: Falta de transporte confiable (%) (16.3 % vs. mediana 8.7 %, +93.8 pp), Sin seguro médico (%) (17.1 % vs. mediana 9.7 %, +93.8 pp), Inactividad física (%) (30.6 % vs. mediana 22.6 %, +93.6 pp).

27. Explicabilidad local: ¿qué determina esta predicción?



Variable	Valor escenario	Mediana	Efecto en P(nivel) (pp)
Falta de transporte confiable (%)	16.3	8.7	93.77
Sin seguro médico (%)	17.1	9.7	93.77
Inactividad física (%)	30.6	22.6	93.6
Tabaquismo (%)	17.3	10.7	93.48
Inseguridad alimentaria (%)	34.6	17.9	91.76
Recibe ayuda alimentaria (SNAP) (%)	33.9	14.1	88
Cribado de colesterol (%)	83.5	87.6	40.86
Inseguridad de vivienda (%)	27.2	14.7	-6.228
Chequeo médico anual (%)	75.5	78	-6.223
Amenaza de corte de servicios (%)	17.6	7.9	-6.212
Falta de apoyo social (%)	31.1	27.2	-3.692
Soledad (%)	37.4	35.7	-2.809
Consumo excesivo de alcohol (%)	17.6	19	-2.375

Cómo se lee. Para cada determinante se reemplaza su valor por la mediana del área (manteniendo el resto) y se mide cuánto cambia la probabilidad del nivel predicho. Rojo = la variable, en su valor actual, aumenta esa probabilidad; azul = la reduce. Es una explicación contrafactual local (tipo ceteris paribus).

Interpretación. Los factores con mayor efecto local son: «Falta de transporte confiable (%)» (+93.8 pp), «Sin seguro médico (%)» (+93.8 pp), «Inactividad física (%)» (+93.6 pp). Intervenir sobre los determinantes en rojo (acercarlos a la mediana) es lo que más reduciría la probabilidad de este nivel según el modelo; la relación es predictiva, no necesariamente causal.